

The background of the slide is a dark, abstract digital landscape. It features a series of glowing, white, vertical lines that resemble data streams or rocket trails, rising from a base of swirling, ethereal blue and white patterns. The top of the image is a deep black space filled with numerous small, bright white stars. The overall aesthetic is futuristic and technological.

Fundamentos de AGI Safety

Clase 5: Artificial General Intelligence, conceptos básicos

Discusión inicial

- ¿Cuál es la tarea **menos** impresionante que tienen gran (90%) confianza **no** podrá ser realizada por AI en los próximos 2/5/10 años?
- ¿Cuál es la tarea **más** impresionante que tienen gran (90%) confianza **podrá** ser realizada por AI en los próximos 2/5/10 años?
- ¿Cuáles serían las consecuencias globales de que haya AI sobrehumana en las distintas categorías de capacidades?

Inteligencia general

Inteligencia

¿Definición?

Propiedades razonables:

- Capacidad de resolver problemas
 - Capacidad de aprendizaje
 - Poder resolver problemas nuevos
 - ¿Lenguaje?
 - ¿Percepción?
 - ¿Capacidad de actuar sobre el mundo?
-

Narrow vs general intelligence

Inteligencia Artificial “débil” (Narrow AI):

- **Definición:** Inteligencia Artificial que está diseñada y entrenada para realizar una tarea específica, pero sin la capacidad de aprender o adaptarse más allá de su función inicial.
- **Ejemplos:** Reconocimiento de voz, recomendaciones de productos en línea, sistemas de navegación GPS.
- **Características clave:**
 - Puede pensarse como una herramienta.
 - Operación solo dentro de un rango limitado o dominio específico.
 - Puede superar a los humanos en su tarea específica pero carece de adaptabilidad a nuevas tareas.

Inteligencia Artificial General (AGI):

- **Definición 1:** Inteligencia artificial que cubre muchos dominios, ya no restringida a una tarea específica.
- **Ejemplo:** ¿Modelos de frontera actuales?
- **Definición 2 (más fuerte):** AI que tiene la capacidad de entender, aprender, y aplicar conocimiento de manera autónoma a una amplia variedad de tareas intelectuales (y subtareas necesarias), aproximadamente al nivel de un humano o mejor. Autonomous, General, Intelligent.
- **Características clave (Def. 2):**
 - Puede pensarse como un agente (tiene objetivos/preferencias hacia los cuales optimiza).
 - Adaptabilidad, entendimiento contextual y aprendizaje autónomo.
 - Capacidad para realizar cualquier tarea intelectual (con resultados externamente observables) que un humano puede hacer.
- **Otras definiciones fuertes:** TAI, PASTA, ASI, speed/quality superintelligence, etc.

¿Cómo formalizar AGI?

Razonamiento

Estimar o calcular resultados a partir de un modelo del mundo.

Teoría de la probabilidad.
¿Entornos computables?

Aprendizaje

Epistemología, teoría de la probabilidad.

Priors. Navaja de Ockham:

Cuando se ofrecen dos o más explicaciones de un fenómeno, es preferible la explicación completa que sea más simple.

Motivaciones/objetivos/ preferencias/valores

Especificaciones, recompensas, función de utilidad.


Un modelo universal de inteligencia general: AIXI

AIXI/AI ξ es un modelo teórico no computable de inteligencia artificial general propuesto por Marcus Hutter ([A Theory of Universal Artificial Intelligence based on Algorithmic Complexity](#)). Representa una forma idealizada de cómo una máquina podría actuar de manera ~óptima en cualquier ambiente computable.

- **Interacción Secuencial:** AIXI interactúa con su entorno mediante una secuencia de acciones y observaciones, aprendiendo de esta interacción para mejorar sus decisiones futuras.
 - **Maximización de la Recompensa:** El objetivo de AIXI es maximizar la suma de las recompensas futuras, tomando decisiones que estén en línea con las experiencias pasadas y las expectativas de recompensa.
-

Formalismo de AIXI

- AIXI es un agente que interactúa con entorno μ , estocástico y desconocido, pero computable, a lo largo de un intervalo fijo de tiempo desde el comienzo $t = 1$ hasta el final $t = m$. (También puede usarse una variante no acotada).
- En cada paso t , el agente elige una acción a_t dentro del conjunto de acciones posibles A .
- Tras una acción, el agente percibe una observación $o_t \in O$ y recibe una recompensa escalar $r_t \in R$. Este par $e_t = (o_t, r_t) \in O \times R = E$ surge de acuerdo a una probabilidad condicional dada por el entorno y el historial completo de acciones/observaciones/recompensas : $\mu(o_t, r_t | a_1, o_1, r_1, \dots, a_{t-1}, o_{t-1}, r_{t-1}, a_t)$.
- La única meta de AIXI es maximizar la suma $\sum_{t=1}^m r_t$ de las recompensas que recibirá.
 - Alternativamente, si el intervalo de tiempo no es finito, se usa una función de descuento γ .



<https://jan.leike.name/AIXI.html>

Política de comportamiento de AIXI

El agente AIXI está asociado con una política particular $\pi: (A \times E)^* \rightarrow A$. Si hasta ahora tomó las acciones $a_1, \dots, a_{t-1}$ y obtuvo las percepciones $o_1 r_1, \dots, o_{t-1} r_{t-1}$, entonces elige la siguiente acción de la siguiente manera:

$$a_t := \arg \max_{a_t} \left(\sum_{o_t r_t} \dots \left(\max_{a_m} \sum_{o_m r_m} [r_t + \dots + r_m] \left(\sum_{q: U(q, a_1 \dots a_m) = o_1 r_1 \dots o_m r_m} 2^{-\text{length}(q)} \right) \right) \right)$$

Donde U es una máquina de Turing cronológica-monótona universal, y los q son ciertas codificaciones de programas.

Metas/objetivos/valores

Preferencias/objetivos

¿Cómo podemos representar una noción de preferencias? ¿Qué propiedades debería cumplir la noción?

Podríamos tener un ordenamiento sobre el conjunto de alternativas posibles, de modo que tengamos $A < B$ si B es preferido estrictamente a A.

Notar que simplemente tener cierto ordenamiento de preferencias no es tan útil, porque, ¿cómo lidiamos con incertidumbre (epistemología, aleatoridad)? ¿cómo comparamos qué tanto mejor es una alternativa a otra?

Función de utilidad: Función real sobre el conjunto de alternativas.

Incetidumbre

- **Teoría de decisión:** La teoría de decisión es un marco interdisciplinario utilizado para entender y modelar cómo los agentes toman decisiones frente a diversas alternativas. Se centra en identificar la mejor elección posible para alcanzar un objetivo específico, bajo la presencia de incertidumbre o conocimiento completo de los posibles resultados.
- **Preferencias racionales:** En el núcleo de la teoría de decisión están las preferencias del agente, que indican cómo este valora, compara, y elige entre diferentes opciones o loterías (conjuntos de posibles resultados con probabilidades asociadas). Las preferencias se consideran racionales cuando cumplen ciertas propiedades que permiten a los agentes tomar decisiones coherentes y consistentes.

$L = \{(x_1, p_1), \dots, (x_n, p_n)\}$ donde los x_i son resultados y los p_i son probabilidades que suman 1.

Axiomas de Von Neumann-Morgenstern

- **Complejitud:** Todo par de loterías puede ser comparado.
- **Transitividad:** Si se prefiere A sobre B y B sobre C, entonces se prefiere A sobre C.
- **Independencia:** Las preferencias entre loterías no cambian si se combinan con loterías idénticas: para toda lotería C y $p \in (0, 1]$, $A \leq B$ si y solo si $pA + (1-p)C \leq pB + (1-p)C$
- **Continuidad:** Si se prefiere A sobre B y B sobre C, existe una lotería intermedia $qA + (1-q)C$ que es indiferente a B.

Función de utilidad VNM

Teorema (VNM): Si agente satisface los axiomas de VNM entonces existe una función real u que asigna valores a los resultados de modo que para cualquier par de loterías L, M ,

$$L \leq M \text{ sii } E(u(L)) \leq E(u(M))$$

donde $E(u(p_1 A_1 + \dots + p_n A_n)) := p_1 u(A_1) + \dots + p_n u(A_n)$,
donde los A_i son resultados.

En la otra dirección, cualquier agente que busque maximizar la expectativa de u obedece los axiomas de VNM.

Esta función es u llamada *función de utilidad de von Neumann-Morgenstern* del agente, o a veces simplemente *función de utilidad*.

Notas

Un agente que no satisface los axiomas VNM tiene agujeros en su proceso de toma de decisiones o es vulnerable a estrategias que explotan las inconsistencias en cómo maneja sus preferencias.

La función de utilidad contiene información fundamental, pero hay complejidades que no están contempladas directamente en la noción básica de función de utilidad:

- Escuela de teoría de decisión
- Resultados acumulativos y decisiones iteradas
- Horizonte de decisiones, descuento
- Etc.

Diversidad de funciones de utilidad

¿Ejemplos?

- Función lineal sobre el dinero que tengo.
- Distancia a la Tierra en pársecs, elevada al cuadrado, multiplicada por cantidad de sistemas solares visitados.
- $\log_2$ (cantidad de sonrisas en el mundo).
- Suma de felicidad de todos los humanos.
 - ¿Definición?
 - Promedio / mediana / mínimo / máximo (pensar qué implica cada variante)
 - Animales / seres sintientes (def?)
 - ¿en la Tierra? ¿universo afectable? ¿universo visible? ¿universos posibles?
- El valor que aparece en cierta región de mi memoria digital.

Algunas variaciones generales:

- Dominio de las preferencias (basada en estados actuales del mundo, historial, acciones, etc.)
- Preferencias indexicales o universales
 - Combinaciones
 - Noción de universalidad fija o expandible?
- Dependientes del tiempo o constantes
- Acotada?
- Simétrica?
- Función cóncava o convexa?
- Etc.

Metas × Capacidades

No hay razón para esperar que la inteligencia requiera o favorezca características mentales antropomórficas, como ser preferencias morales humanas.

Tesis de ortogonalidad (Bostrom) *En el espacio de mentes posibles, metas/preferencias e inteligencia son ejes ortogonales. En principio, casi cualquier nivel de inteligencia puede ser combinado con casi cualquier meta/preferencia.*

Objetivos terminales y objetivos instrumentales

Objetivos terminales: Estados del mundo (en sentido amplio) deseables en sí mismos, metas que cierto agente específico busca.

- **Ejemplos:**
 - Preservación de cierta especie animal.
 - Creación de sociedad utópica post-escasez.
 - Minimizar error de predicción visual.
- **Características:**
 - Intrínsecamente valiosos para ese agente; no requieren justificación adicional.

Objetivos instrumentales: Medios o acciones que se emprenden para alcanzar los objetivos terminales.

- **Ejemplos:**
 - Campañas de conservación, creación de hábitats artificiales.
 - Estudio de psicología, sociología, desarrollo de fusión nuclear barata.
 - Aprender óptica, física, biología, etc. Ir a ambientes predecibles.
- **Características:**
 - Suelen ser más específicos y tangibles.
 - Su valor para el agente depende únicamente de cuánto aportan hacia una meta terminal.

Convergencia instrumental

¿Cómo dependen las acciones de un agente de sus objetivos terminales (es decir, de sus metas/valores/etcétera)? ¿Se puede predecir algo sobre objetivos instrumentales sin saber los terminales?

Tesis de convergencia instrumental: Hay varias metas instrumentales que son beneficiosas/compatibles con un amplio rango de metas terminales.

Algunas metas instrumentales ampliamente útiles:

- Auto-preservación
- Preservación de metas terminales
- Auto-mejora
- Mejoras científicas/tecnológicas
- Adquisición de recursos

Cosas para hacer o pensar

- ¿Qué clases de comportamientos interesantes dependen fuertemente propiedades de la función de utilidad?
 - Preferencias sobre estado del mundo versus realizar ciertas acciones
 - Propiedades matemáticas de la función
 - Variaciones temporales
- ¿Se pueden poner condiciones sobre la función de utilidad que restrinjan la aparición de ciertas metas instrumentales convergentes?
- Leer *The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents*.

AI safety

Alineamiento (AI alignment)

En 1960, Norbert Wiener articuló una versión del problema del alineamiento:

“If we use, to achieve our purposes, a mechanical agency with whose operation we cannot interfere effectively [...] we had better be quite sure that the purpose put into the machine is the purpose which we really desire and not merely a colorful imitation of it.”

Esto es lo que hoy se conocería como el problema de **value alignment**, o más precisamente como el problema de **goalcraft** (que incluye el problema de outer alignment). Notar que ya esto parece extremadamente difícil, dada la complejidad y fragilidad de los valores humanos.

Otro problema es el de **aimability** (que incluye el problema de inner alignment), cómo introducir metas concretas en sistemas de AI.

El alineamiento es quizás el problema fundamental de AI (existential) safety. ¿Cuáles serían las consecuencias de AGI no alineada con los valores humanos?

Breve historia de AI (existential) safety

- **1872, Erewhon (Samuel Butler):** *“I fear none of the existing machines; what I fear is the extraordinary rapidity with which they are becoming something very different to what they are at present”.*
 - **1951, Alan Turing:** *“At some stage therefore we should have to expect the machines to take control”.*
 - **1960, Norbert Wiener:** *“we had better be quite sure that the purpose put into the machine is the purpose which we really desire and not merely a colorful imitation of it”.*
 - **1965, I.J. Good:** Concepto de “explosión de inteligencia”. *“Let an ultraintelligent machine be defined as a machine that can far surpass all the intellectual activities of any man however clever. Since the design of machines is one of these intellectual activities, an ultraintelligent machine could design even better machines; there would then unquestionably be an 'intelligence explosion,' and the intelligence of man would be left far behind... Thus the first ultraintelligent machine is the last invention that man need ever make, provided that the machine is docile enough to tell us how to keep it under control.”*
-

Breve historia de AI (existential) safety

- **2002, Nick Bostrom:** Concepto de riesgo existencial. Un evento que causaría gran daño a escala global al bienestar humano es un riesgo global catastrófico. Si amenaza extinción de la humanidad o una drástica y permanente reducción en su potencial, es un *riesgo existencial*.
 - **2008, Eliezer Yudkowsky:** Compilación de varias nociones iniciales de AI safety.
 - **2014, Nick Bostrom:** Publicación de *Superintelligence*. Riesgos existenciales por AI.
 - **2016, D. Amodei, C. Olah, J. Steinhardt, P. Christiano, J. Schulman, D. Mané:** Concrete problems in AI safety. Negative side effects, reward hacking, scalable oversight, safe exploration, distributional shift.
 - **2019, Stuart Russell:** *Human compatible: AI and the problem of control*.
 - **2023, mayo:** Statement on AI Risk: “Mitigating the risk of extinction from AI should be a global priority alongside other societal-scale risks such as pandemics and nuclear war”
 - Firmado por Geoffrey Hinton, Yoshua Bengio, Dario Amodei, Sam Altman, Ilya Sutskever, Demis Hassabis, et al.
 - **2023, noviembre:** UK AI safety summit. Bletchley declaration.
 - **2024, agosto:** La AI Act de la Unión Europea empieza a entrar en vigor de manera escalonada, con un capítulo para proveedores de modelos de General-Purpose AI que empieza a aplicar en 2025 .
 - **2025, septiembre:** Se aprueba en California la *Transparency in Frontier Artificial Intelligence Act*.
- 

Algunas áreas de AI safety

- Alineamiento
 - (Robust) goal specification, value learning
 - Aimability
 - Corregibilidad
 - Etc.
 - Control
 - Interpretabilidad
 - Métodos de evaluación y verificación
 - Containment, control de capacidades
 - Etc.
 - Gobernanza
- [Unsolved Problems in ML Safety](#) (2022)
 - Robustness
 - Monitoring
 - Alignment
 - Systemic safety
 - [Foundational Challenges in Assuring Alignment and Safety of Large Language Models](#) (abril, 2024)
 - [An Approach to Technical AGI Safety and Security](#) (abril 2025)

Cosas para pensar o profundizar

- ¿Qué tipos de riesgos aparecen ante distintas categorías/niveles de capacidades de AI?
 - Pensar en usos maliciosos, autónomos, y dinámicas globales.
 - ¿Cuál sería la *máxima* capacidad general de una AI tal que, por más que no esté alineada, probablemente no representaría un riesgo catastrófico?
 - ¿Cuál sería la *mínima* capacidad general de una AI no alineada que representaría un riesgo existencial sustancial?
- Pensar en los problemas de goalcraft y aimability. ¿Qué dificultades tienen?
- Leer *Concrete problems in AI safety* y *Unsolved problems in ML safety*.