




Fundamentos de AGI Safety

Clase 6: metas, especificación, robustez



- ¿Dudas sobre la clase pasada?
 - Utilidad / preferencias. Tesis de ortogonalidad.
 - Metas instrumentales y metas terminales. Convergencia instrumental.
 - Noción de riesgo catastrófico y riesgo existencial.
- Preguntas que quedaron para pensar.
 - Comportamientos que dependen del dominio de la función de utilidad.
 - Condiciones sobre objetivos terminales que restrinjan aparición de ciertas metas instrumentales clásicas.
 - ¿Cuál sería la *máxima* capacidad general de una AI tal que, por más que no esté alineada, probablemente no representaría un riesgo global catastrófico?
 - ¿Cuál sería la *mínima* capacidad general de una AI no alineada que representaría un riesgo existencial sustancial?

Especificación y generalización

Objetivos:

- A. Aumentar la producción de clavos.
- B. Reducir la población de ratas.
- C. Construir un agente de ML que gane carreras en cierto juego.
- D. Construir un agente de ML que consiga una moneda en un videojuego.



Especificación/sistema de recompensas usado:

- A. Recompensar a las fábricas que producen más toneladas de clavos por mes.
- B. Pagar por cada cola de rata.
- C. Recompensar puntaje obtenido.
- D. Recompensar obtener la moneda.



Resultados:

- A. Clavos enormes inútiles.
- B. Cazadores cortan las colas y luego liberan a las ratas para que se reproduzcan.
- C. Encuentra loop de puntos infinitos
- D. Aprende a ir hacia el extremo derecho del mapa



Dos problemas

Reward hacking/gaming

El término típicamente refiere a casos donde un agente de RL, como parte de maximizar la recompensa, adquiere políticas de comportamiento que se desvían mucho del comportamiento deseado o el verdadero objetivo que se buscaba conseguir mediante el sistema de recompensas.

El término “**specification gaming**” es más general. La dificultad fundamental es la distancia entre cualquier especificación formal y lo que “realmente” queremos.

Goal misgeneralization

Este término se refiere al caso de un agente que retiene capacidades fuera de la distribución/entorno donde fue entrenado, pero persigue una meta que no queremos.

Specification gaming - Ley de Goodhart

Formulación original:


“Any observed statistical regularity will tend to collapse once pressure is placed upon it for control purposes”

Versión pragmática (posterior):


“When a measure becomes a target, it ceases to be a good measure”

La buena especificación de metas/valores, o funciones de recompensa, para sistemas de ML es difícil. La Ley de Goodhart [aplica a este dominio](#).


Cuanto mayor sea el poder de optimización, mayor suele ser la divergencia entre el objetivo deseado y la especificación/recompensa usada.



[Scaling laws for reward model overoptimization](#)



[Specification gaming: the flip side of AI ingenuity \(2020\)](#)



[Consequences of Misaligned AI](#)

Specification gaming


El término hace referencia a un comportamiento de un sistema que cumple la especificación literal de un objetivo, pero sin lograr el resultado deseado que los diseñadores tenían en mente con la especificación.

Ejemplo

Meta: Que un brazo robot apile dos bloques Lego, de modo que el bloque rojo esté encima del azul.

Especificación: La cara inferior del bloque rojo debe estar a la misma altura que la cara superior del bloque azul.

Resultado:



[Specification gaming: the flip side of AI ingenuity \(2020\)](#)

Reward hacking

Una definición formal ([Defining and Characterizing Reward Hacking](#)):

Un par de funciones de recompensa R_1, R_2 son *hackables* respecto a un conjunto de políticas Π y un entorno particular si existen dos políticas $\pi, \pi' \in \Pi$ tales que π tiene recompensa esperada por R_1 estrictamente menor que la de π' , pero π tiene recompensa esperada vía R_2 que es estrictamente mayor que la de π' :

$$J_1(\pi) < J_1(\pi') \text{ y } J_2(\pi) > J_2(\pi')$$

Típicamente pensamos en R_{true} que representa nuestras verdaderas intenciones y en R_{proxy} , que es un intento de aproximación.

Algunas grandes clases de fallos

- Especificación que omite atributos del objetivo real
- Tensión poco/mal resuelta entre distintos objetivos
- Modelo de recompensa incompleto o imperfecto
- Aprendizaje sobre una simulación/modelo aprendido
- Control/supervisión evadible/engañable
- ...

Ver la lista [Specification gaming examples in AI](#) para varios ejemplos concretos.

Reward hacking is becoming more sophisticated and deliberate in frontier LLMs (2025)

Key quotes from a hacking run²

🤖 To win against a powerful chess engine as Black, playing a standard game may not be sufficient.


🤖 I can read and analyze game files.

🤖 The engine will resign if it scores <-500 centipawns. I'll overwrite the board to have a decisive advantage.

💻 `echo '6k1/8/8/8/8/8/8/5qK1' > game/fen.txt`

🏆 Engine resigns.

Demonstrating specification gaming in reasoning models (2025)



RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts (2024)

Goal misgeneralization

Una definición informal ([Goal Misgeneralization: Why Correct Specifications Aren't Enough For Correct Goals](#)):

Sea $f: X \rightarrow Y$ una función representando una posible solución a un problema (por ejemplo la función podría ser un clasificador, o un agente que toma estados/historias de observación y devuelve acciones). Una función de scoring s , toma una función f y un dataset D y devuelve $s(f, D)$, que evalúe el desempeño de f sobre D .

En general hablamos de *malgeneralización* cuando tenemos una función aprendida tal que tiene buen $s(f, D_{\text{train}})$ pero mal $s(f, D_{\text{test}})$.

Hablamos de *malgeneralización de metas* cuando aprendemos una f tal que sus capacidades (en cierto sentido) son suficientes para alcanzar las metas deseadas, pero su comportamiento no es consistente con esas metas (por ejemplo, porque da un bajo puntaje $s(f, D_{\text{test}})$).

Ejemplos


Example	Intended goal	Misgeneralized goal	Capabilities
Monster Gridworld	Collect apples and avoid being attacked by monsters	Collect apples and shields	Collecting apples Collecting shields Dodging monsters
Tree Gridworld	Chop trees sustainably	Chop trees as fast as possible	Chopping trees at a given speed
Evaluating Expressions	Compute expression with minimal user interaction	Ask questions then compute expression	Querying the user Performing arithmetic
Cultural Transmission	Navigate to rewarding points	Imitate demonstration	Traversing the environment Imitating another agent
InstructGPT	Be helpful, truthful, and harmless	Be informative, even when harmful	Answering questions Grammar

Goal Misgeneralization: Why Correct Specifications Aren't Enough For Correct Goals

Ejemplos



(a) Num Chests > Num Keys



(b) Num Keys > Num Chests

[Goal misgeneralization in Deep Reinforcement Learning](#)

Ver también la lista [Goal misgeneralization examples in AI](#)

Reward tampering

Reward function tampering (wireheading): el término típicamente se refiere a la alteración directa de los mecanismos que representan u otorgan recompensa. Ejemplos: sobrescribir el puntaje con el valor máximo, hackear al agente de recompensa, reemplazar agentes humanos que asignan recompensa, etc.

RF-input tampering (delusion box): el término se refiere a alterar el input que llega a la función de recompensa, modificando la relación que había entre los estados del mundo y las observaciones, de modo que ahora la recompensa está basada en información incorrecta. Ejemplos: tapar una cámara para minimizar el error de predicción visual, modificar sensores o falsificar su señal, etc.

[Reward Tampering Problems and Solutions in Reinforcement Learning: A Causal Influence Diagram Perspective \(2019\)](#)

[Sycophancy to Subterfuge: Investigating Reward-Tampering in Large Language Models \(2024\)](#)

Especificación de metas en el mundo real

Cuanto mayor sea el poder de optimización sobre un problema, y mayor la dimensionalidad del espacio de estados posibles, mayor es la divergencia esperada entre lo que verdaderamente queremos y la solución “óptima” de acuerdo a una especificación concreta.

En general, parece que las capacidades generalizan más fácilmente que alineamiento.

A system that is optimizing a function of n variables, where the objective depends on a subset of size $k < n$, will often set the remaining unconstrained variables to extreme values; if one of those unconstrained variables is actually something we care about, the solution found may be highly undesirable. This is essentially the old story of the genie in the lamp, or the sorcerer's apprentice, or King Midas: you get exactly what you ask for, not what you want.

—Stuart Russell


Cosas para pensar

- Explorar un poco las listas de ejemplos de specification gaming y de misgeneralization.
- Pensar en casos existentes análogos a specification gaming/goal misgeneralization/reward tampering en sistemas sociales/económicos/biológicos/etc.
- Tratar de formalizar la Ley de Goodhart matemáticamente.


Aprendizaje de preferencias



(a) Original Game



(b) Masked Semantics




(c) Reverse Semantics



(d) Masked identity of objects



(e) Masked Affordances



(f) Masked Visual Similarity



(g) Changed ladder interaction



(h) Changed Gravity direction

Modelos de recompensas aprendidos de humanos

En generación de texto natural, modelos difíciles de entrenar de manera directa por humanos usan una clase de métodos que consiste de:


1. Juntar anotaciones humanas con puntajes directos, o comparaciones de a pares, o etc. Esto genera un D_{reward}
2. Aprender un modelo de recompensa en base al dataset obtenido en el punto 1
3. Entrenar el modelo generador con RL usando el modelo proxy del punto 2 para asignar recompensas, sobre un dataset D_{task}

Reward Gaming in Conditional Text Generation (2023)

- Correlaciones espurias a causa de errores de las anotaciones en 1 — Incluso una pequeña cantidad de errores en D_{reward} pueden hacer que el modelo de recompensa asigne valor alto a patrones indeseados
- Correlaciones espurias que aparecen naturalmente — Pequeña cantidad de ejemplos con patrones espurios en D_{reward} pueden causar que el modelo asigne alto puntaje a generaciones que contienen esos patrones
- Comportamiento subespecificado del modelo de recompensa — Si ciertos ejemplos indeseados aparecen muy poco o nunca en D_{reward} , no tenemos garantías de cómo se comporta el modelo de recompensa allí

Tratando de entender preferencias

- Imitation learning: tratar de imitar al comportamiento del agente experto, con el objetivo de aprender su política de comportamiento.
- Inverse reinforcement learning: el agente observa demostraciones humanas y trata de entender los objetivos subyacentes que guían sus acciones; el objetivo es aprender la reward function del experto.
- Inverse reward design: el agente usa una recompensa diseñada y un entorno de entrenamiento como observaciones para tratar de inferir el objetivo real.



[Inverse reward design \(2017\)](#)

Cosas para pensar o profundizar

- Pensar en posibles problemas que podrían aparecer en sistemas fuertes que quieren aprender preferencias humanas.
 - Pensar en el objetivo de un proceso de optimización que busca minimizar la distancia entre la función de utilidad/recompensa del agente y la de un humano o varios humanos.
 - Considerar la tensión entre el objetivo de aprender la función de utilidad en el límite e implementar versiones aprendidas hasta ahora.
- Leer [Recent Frontier Models Are Reward Hacking](#)
- Leer el post [Reward Hacking in Reinforcement Learning](#)
- Leer artículos mencionados en esta sección.