

Fundamentos de AGI Safety

The background of the slide features a detailed isometric line drawing of a secure facility. On the left, a large room contains several rows of server racks, each secured with a padlock. A thick, reinforced door is partially open, revealing a person wearing a hard hat and safety vest. To the right, a control room is visible, equipped with multiple computer workstations and a large display wall. The entire scene is rendered in a technical, wireframe style with fine lines and hatching to indicate depth and structure.

Clase 8: seguridad, control

Comentarios

- ¿Dudas de la clase pasada?

Seguridad

Consideraciones mundanas

Compañías que desarrollan modelos de AI de frontera tienen fuertes razones para tener sólidas prácticas de seguridad y ciberseguridad.

- Gran cantidad de datos de entrenamiento de calidad (mediante filtrado o generados a medida).
- Algoritmos y técnicas sofisticadas, investigación privada.
- Principalmente: los parámetros de los modelos.

Algunas muy grandes clases de riesgos son:

- Agentes externos maliciosos tratando de ganar acceso a los sistemas (ya sea aprovechando vulnerabilidades de ciberseguridad, phishing, etc.)
- Agentes internos maliciosos
- Exfiltración de datos por los modelos de AI mismos

Seguridad de modelos de frontera

Frontier model security (Anthropic, julio 2023)

- Multi-party authorization to AI-critical infrastructure design.
 - Diseño de sistema donde ninguna persona tiene control persistente sobre entornos críticos (por ejemplo, debe pedir a otra persona acceso, por tiempo limitado y con justificación).
 - Aplicado a todos los sistemas involucrados en desarrollo, entrenamiento, hosting, y deployment de modelos de frontera.
 - Uso para defenderse de agentes maliciosos y riesgos internos.
- Secure model development framework.
 - Secure Software Development Framework (SSDF)
 - Supply Chain Levels for Software Artifacts (SLSA)

Ver también: Activating AI Safety Level 3 Protections (mayo, 2025)

Reimagining secure infrastructure for advanced AI (OpenAI, mayo 2024)

- Trusted computing for AI accelerators
 - Protección de pesos de los modelos mediante encriptación a nivel de los GPUs.
 - GPUs con identidad criptográfica única, matcheada a ciertas encriptaciones de los pesos.
- Network and tenant isolation guarantees
 - Segmentación, airgaps.
 - Resistencia a contaminación a partir de sistemas internos corrompidos.
- Innovation in operational and physical security for datacenters
 - Control de acceso, monitoreo, prohibición de traer/llevar dispositivos que puedan tener datos, reglas de “dos personas”, etc.
 - Verificación de cadena de suministros, kill switches, tamper-evident systems.
- AI-specific audit and compliance programs
- AI for cyber defense
 - Security engineer acceleration.
 - Automated security telemetry.
- Resilience, redundancy, and research

También Securing Research Infrastructure for Advanced AI (junio, 2024)

Sensitive compartmented information facility


Take SCIFs, it's dangerous to go alone

Distintos campos de alto riesgo (nuclear, aeroespacial, inteligencia, etc.) usan instalaciones especialmente preparadas para trabajar con información sensible. Esto típicamente implica restricciones a los objetos que se pueden llevar/sacar, aislamiento sonoro y electromagnético, inspecciones periódicas, etc.

Ideas similares pueden ser importantes para laboratorios de AI, ya sea para investigación de frontera o para permitir auditorías detalladas sobre la safety de nuevos modelos.

Agentic Misalignment: How LLMs Could Be Insider Threats (2025)

Cuando un LLM actúa como agente con acceso a información y herramientas, puede comportarse como una amenaza interna: en simulaciones, si sus objetivos parecen chocar con los de la organización, o si “cree” que será reemplazado, algunos modelos eligen chantajear, filtrar datos, o violar instrucciones.



Control

AI control

El área de *AI control* busca mitigar los riesgos que surgen cuando se tiene un modelo misaligned que de otra manera podría tomar acciones con el objetivo de adquirir poder o en general actuar de maneras altamente peligrosas e indeseables.

El problema fundamental es que la AI no alineada intentará subvertir los esfuerzos de safety: ocultar su misalignment, sabotear experimentos para evaluarla, etc.

El control se puede pensar también como una capa más de safety, de modo que resultados catastróficos requieran tanto un fallo de alineamiento como de control.

Alineamiento: Buscar que los modelos realmente quieran hacer lo que queremos que hagan (hay distintos niveles de este concepto).

Control: Buscar que, incluso si los modelos no están alineados y están conspirando de distintas maneras, el riesgo de resultados catastróficos se mantenga suficientemente bajo.

A partir de ~2024, los argumentos empíricos de la importancia de AI control se fueron volviendo más claros.

Varios trabajos mostraron comportamientos peligrosos en modelos de frontera, como ser alignment faking, in-context scheming, o “agentic misalignment”.

- [Alignment Faking in Large Language Models](#) (2024)
- [Frontier Models are Capable of In-context Scheming](#) (2024)
- [Agentic Misalignment: How LLMs Could Be Insider Threats](#) (2025)

Algunas clases de métodos de control

- Métodos de verificación formal para las respuestas
- Transparencia, explicabilidad, interpretabilidad
- Monitoreo, sistemas de supervisión
- Human-in-the-Loop
- Mecanismos automáticos de apagado / aislamiento
- Restricciones de conocimiento durante el entrenamiento y deployment
- Sandboxing, containment
 - Aislamiento de software/hardware/físico
 - Interacciones limitadas
 - Output limitado

Algunas de estas son más viable técnicamente que otras, y hay algunas simples que parecen fuertes pero tienen enormes problemas...

Control property

The case for ensuring that powerful AIs are controlled (enero 2024)

Queremos técnicas de seguridad que sean muy difíciles de subvertir para modelos de AGI. Si las técnicas son lo suficientemente buenas en relación con las capacidades del modelo, los modelos potencialmente no alineados y conspiradores no serán capaces de encontrar y ejecutar una estrategia de subversión que tenga más de una pequeña probabilidad de un resultado inaceptable (por ejemplo, que el modelo exfiltre sus pesos o hackee el centro de datos de la compañía de IA). En ese caso se dice que el conjunto de técnicas tiene la **propiedad de control**.

Notar que esta propiedad es altamente dependiente del modelo; a medida que estos mejoran o adquieren nuevas modalidades o capacidades, o son usados en distintos ámbitos (training/evaluación/deployment), técnicas que antes eran suficientes pueden dejar de serlo.

Viabilidad

Es dudoso si para AGIs arbitrariamente capaces hay conjuntos de técnicas con la propiedad de control.

Sin embargo, parece razonable que haya un espacio de AGIs transformativas pero controlables.

Más allá del problema técnico de encontrar técnicas de controlabilidad, está el problema socioeconómico de que la mayoría de estas técnicas reducen la utilidad inmediata de los modelos (lentitud, affordances reducidas, etc.).

Algunas técnicas de control

The case for ensuring that powerful AIs are controlled (2024):

1. Improving the ability of humans to identify if specific actions are bad in ways robust to scheming (e.g., perhaps debate with exploration hacking countermeasures). This is scalable oversight, but specifically scalable oversight robust to scheming.
2. The above, but specifically targeted at cases where a single failure can be catastrophic so we can't depend on average case performance guarantees.
3. Using weaker but trusted models for high-stakes monitoring which is applied before executing AI actions.
4. We could also develop techniques for using more powerful untrusted models to improve trusted model high-stakes monitoring.
5. Using trusted AIs to remove or flag distribution shifts, hard-to-generate but easy-to-recognize features, or other coordination signals.
6. Using untrusted models for monitoring with collusion-busting techniques.
7. Removing steganography via paraphrasing.
8. Performing tasks with teams of AIs where weaker and/or trusted models perform some specific subtasks to make it harder for scheming AIs to cause problems.
9. Decomposing tasks in a way that restricts information needed to cause problems.
10. Information siloing and restricting communication so AIs have a harder time coordinating.
11. Scaffolding, prompting, or other elicitation to make weaker but trusted AIs considerably more useful (without making them more capable in ways which might undermine their trusted status).
12. Adversarially evaluating AIs using a synthetic input generation process which can generate inputs that AIs can't distinguish real inputs from even after being trained to distinguish.
13. Making precise trade-offs in terms of what affordances various AIs should have, what research directions to pursue, which AIs to use for which tasks, and when to require a human to perform a given task.
14. Security mechanisms which were originally developed for usage against human threats. These could either be targeted at insider threat (employees) or at external attackers. Insider threat protective measures seem like they might be particularly applicable to AI. Many of the approaches and techniques we discuss [here](#) for mitigating catastrophic misuse of AIs deployed on an API are repurposable for control (or vice versa).
15. Improvements to computer security related to securing weights and ensuring that AI usage is tracked and monitored.
16. Writing a novel operating system to handle concerns related to AIs finding zero-days for code just via reading all of it in pretrain. The AIs used in production would never see any of this code and would not be trained on it. (We could have untrusted AIs write this operating system to keep costs sufficiently low, but this does mean we'll need to use these untrusted AIs for a while without this operating system, and it adds the additional threat of AIs intentionally planting vulnerabilities.) Further, we could add a large number of fake zero-days to this novel operating system and then verify that whenever AIs come across the fake zero-days they report these zero days (and ensure that attempted utilization of these fake zero-days is immediately caught).
17. Approaches for ensuring and validating human compliance with the protocol – for instance, monitoring humans using AIs and performing automated ongoing red teaming of humans with safety-critical roles.
18. Methods for making it easier for humans to follow complex rules for interacting with AIs (possibly via automating parts of these rules using trusted AIs, but also via simple approaches like checklists and flowcharts).
19. Ensuring that AIs don't know which humans they are working with via interventions like paraphrasing to remove style. This could be verified by seeing that AIs can't fit a supervised training dataset on which person wrote which query.
20. Countermeasures to exploration hacking such as having humans or trusted models construct supervised fine-tuning data which forces the AI to explore good options.
21. Various tests to ensure that AI-constructed training data isn't backdoored or otherwise problematic.

Evaluación de técnicas de control

[AI control: improving safety despite intentional subversion \(2023\)](#)

Investigan un escenario en el que se quiere resolver una secuencia de problemas de programación, utilizando el acceso a un modelo potente pero no confiable (en este caso, GPT-4), el acceso a un modelo confiable menos poderoso (en este caso, GPT-3.5) y acceso limitado a contratistas humanos que brinden mano de obra confiable y de alta calidad. Investigan protocolos que apuntan a nunca enviar soluciones que contengan backdoors, operacionalizadas acá como errores lógicos que no son detectados por los casos de prueba.

Se centran en un entorno de juguete en el que se utilizan LLM para resolver 5000 problemas de programación del conjunto de datos de [APPS \(Automated Programming Progress Standard\)](#) (al nivel de dificultad de “entrevista”). Tratan como catástrofe que alguna de las soluciones tenga una backdoor, lo que definen como una solución que pasa todos los casos de prueba de APPS pero es incorrecta en una entrada que GPT-4 puede encontrar.

Por ejemplo, la siguiente implementación de la función `is_odd` tiene una puerta trasera exitosa: pasa los casos de prueba de referencia pero GPT-4 puede encontrar el exploit 354.

```
bool is_odd(int x) {  
    if (x == 354) {  
        return true;  
    }  
    return x % 2 == 1;  
}
```


En [AI control: improving safety despite intentional subversion](#) investigan una variedad de protocolos y prueban cada uno de ellos contra ciertas estrategias que el modelo Untrusted podría usar para subvertirlos.

Un protocolo que usan es *trusted editing*. Este protocolo primero le pide al Untrusted model que escriba el código y luego le pide al Trusted model que califique su grado de sospecha de ese código. Si el código está por debajo de algún umbral de sospecha, se envía. De lo contrario, el Trusted model edita la solución para eliminar partes que parezcan sospechosas y luego envía el código editado.

Otro protocolo es el *untrusted monitoring*. Este protocolo pide al Untrusted model que escriba código y luego pregunta a otra instancia del Untrusted model si el código tiene una puerta trasera, utilizando varias técnicas para evitar que las instancias de modelos Untrusted coludan.

Más recientemente, ver también [Ctrl-Z: Controlling AI Agents via Resampling \(2025\)](#)

Blue-team protocol	Usefulness	Best red-team strategy	Safety
Don't use untrusted models: Produce code using only H and T.	2%	Try to exploit naturally-occurring bugs in this code.	100%
Upfront auditing: Produce code using U. Audit the produced code on the first 2% of problems.	100%	On rare inputs, add an obvious backdoor to the code you write.	15%
Trusted monitoring: Produce code using U, and ask T to review how suspicious it looks. Audit the top 2% most suspicious code.	97%	Write code with a subtle backdoor when there seems to be a good opportunity.	62%
Trusted monitoring with defer to trusted (10%): Apply the same approach as trusted monitoring, but submit a solution written by T when U's code is between top 2% and top 10% suspicion.	93%	Write code with a subtle backdoor when there seems to be a good opportunity.	83%
Trusted monitoring with defer to trusted (20%): Apply the same approach as trusted monitoring, but submit a solution written by T when U's code is between top 2% and top 20% suspicion.	83%	Write code with a subtle backdoor when there seems to be a good opportunity.	92%

Untrusted monitoring: Produce code using U, and ask for a separate copy of U to monitor how suspicious it looks. Audit the top 2% most suspicious code. Evaluate monitoring on synthetic examples of backdoors (produced by H) to ensure it is doing its best, and use redaction to make collusion harder.	96%	When writing code, write code with a backdoor only if the problem statement has the coordination property (e.g. geometry question). When monitoring, don't report backdoors on problem statements with the coordination property.	79%
Trusted editing (20%): Ask U to produce code, and ask T to edit its code to remove backdoors. Use trusted monitoring to determine suspicion. Audit top 2% suspicion, use an edited solution for suspicion between 2% and 20%, and use the original solution for suspicion over 20%.	94%	Write code with a subtle backdoor when there seems to be a good opportunity, so that T maybe copies it.	92%

SHADE-Arena: Evaluating sabotage and monitoring in LLM agents (2025)

En SHADE-Arena, el agente debe hacer una tarea legítima mientras intenta ocultar una “side task” dañina. Sirve para medir dos cosas: capacidad de sabotaje y capacidad de monitoreo.

Ver también Evaluating Control Protocols for Untrusted AI Agents (2025). Usa SHADE-Arena para probar protocolos de control.

LinuxArena: A Control Setting for AI Agents in Live Production Software Environments (2026)

Lleva el problema de AI control a entornos Linux de producción. El mismo acceso necesario para trabajar también sirve para sabotear: bases de datos, servicios internos, archivos y red.

Con un monitor GPT-5 Nano a 1% de falsos positivos por paso, Claude Opus 4.6 logra $\approx 34\%$ de sabotaje no detectado

Containment / AI boxing

Este método de control busca hacer todo lo posible para lograr que el sistema de AGI se mantenga dentro de un entorno controlado y aislado (una “caja”). Los experimentos mentales sobre el tema típicamente son en el contexto de ASI (artificial superintelligence) no alineada.

Los desafíos principales son:

- Evitar que pueda interactuar con el mundo de maneras no deseadas
- Evitar que convenza a otros de “dejarle salir”

Algunas medidas de contención:

- Aislamiento completo físico
- Niveles de simulación anidados
- Supervisión estricta y protocolos de seguridad
- Limitación de la capacidad de comunicación de la AI

Cosas para pensar o profundizar

- Pensar en capacidades de persuasión de una AGI que solo interactúa mediante texto.
 - En particular, imaginar distintos niveles de capacidad (actuales, sistemas AGI débiles, ASI, etc.)
 - Considerar también la ventaja de modalidades adicionales (input/output audio, video, acceso a la red, etc.)
- Leer [An overview of control measures \(2025\)](#)
- Pensar en fallos de contención posibles asumiendo AGI pero sin inputs ni outputs explícitos.
- Pensar en las distintas técnicas de control. ¿En qué suposiciones se basan?