

Fundamentos de AGI Safety

Clase 10: supervisión escalable (y otras cosas)



Comentarios

- ¿Dudas del informe 2?
- ¿Dudas de la clase anterior?

Supervisión escalable

La dificultad de supervisar modelos fuertes

Un modelo puede ser difícil de supervisar por varias razones:

- Produce soluciones que no sabemos verificar
- Puede aprovechar errores del mecanismo de supervisión
- Entiende consecuencias que no podemos inferir u observar
- Tiene comportamientos agénticos, sus propias metas más allá del episodio actual, y capacidades para actuar sobre el mundo externo

Asociado con
agendas de
honesty y ELK



Asociado con
la agenda de
Oracle AI



Scalable oversight

El problema fundamental de scalable oversight es el de conseguir métodos para supervisar modelos con capacidades *sobrehumanas*, como por ejemplo para dar buenas señales de RL/etiquetado/críticas en situaciones en las cuales no sería factible usar humanos.

Se busca en estos casos amplificar las capacidades del sistema de supervisión, de modo que resulten mayores que las del modelo supervisado (por ejemplo dándole un scaffolding especial al supervisor, más poder de cómputo, forzando un sistema de argumentación adversarial, etc.)

Ver:

- [Measuring Progress on Scalable Oversight for Large Language Models \(2022\)](#)
- [A bird's eye view of ARC's research \(2024\)](#)
- [Scaling Laws For Scalable Oversight \(2025\)](#)
- [Recommendations for Technical AI Safety Research Directions \(2025\)](#)

Scalable oversight

¿Cómo podemos amplificar al supervisor?


- Asistencia: Darle al evaluador herramientas para detectar errores. Críticas, búsqueda, herramientas, muestreo múltiple.
- Descomposición: Convertir una tarea en subtareas verificables. Iterated Distillation and Amplification, recursive reward modeling
- Protocolos adversariales: Hacer que otros modelos expongan errores o problemas. Debate, consultancy, prover-verifier.
- Generalización favorable / bootstrapping: Entrenar con señales débiles tratando de que la generalización vaya en direcciones buenas. Weak-to-strong generalization, easy-to-hard, supervisión recursiva.

También, como una estrategia parcialmente alternativa:

- Garantías formales: Reducir la dependencia de juicios humanos mediante especificaciones y verificadores. [Guaranteed Safe AI](#).

Debate

AI safety via debate (2018). Protocolo que puede ayudar en contextos donde el juez puede verificar confiablemente los argumentos usados en el debate entre dos agentes adversariales entre sí.




On scalable oversight with weak LLMs judging strong LLMs (2024). Hacen experimentos diversos de debate y consultancy, con jueces débiles y agentes fuertes, explorando distintos tipos de asimetrías.

Weak-to-strong generalization

Este método busca que un “estudiante” fuerte aprenda correctamente a pesar de la imperfección de las señales dadas por un modelo supervisor débil.

[Weak-to-strong generalization \(2023\)](#)

Pero: [Super\(ficial\)-alignment: Strong Models May Deceive Weak Models in Weak-to-Strong Generalization \(2024\)](#)



Weak-to-strong researcher


Automated Weak-to-Strong Researcher (2026)

Crean agentes que proponen ideas, hacen experimentos, e iteran en el problema de cómo entrenar a un modelo fuerte usando solo la supervisión de un modelo más débil. Estos agentes tienen mejor desempeño en esta tarea que investigadores humanos.


- problema delimitado
- experimentos automatizables
- métrica clara
- muchas iteraciones paralelas

Ahora, ¿qué ocurre en tareas difusas donde el error importante es justamente el que los humanos no saben detectar?


Human-tuned baselines across datasets




Do AAR-discovered ideas transfer to held-out datasets?



Automated alignment is harder than you think (2026)



Some research outputs are incorrect, leading to an incorrect OSA.



Scaling Laws For Scalable Oversight (2025).

Entre otras cosas, estudian Nested Scalable Oversight, donde modelos en los que se confía supervisan otros más fuertes, que luego se vuelven el modelo confiado en la próxima generación.

En general ven que las tasas de supervisión exitosa decrecen a medida que crece la brecha entre capacidades.

1. Oversight Simulations



2. Elo Modeling



3. Protocol Optimization




Otra estrategia: Guaranteed Safe AI

Tres componentes:


- World model: Descripción matemática de cómo el sistema afecta al mundo.
- Safety specification: Descripción matemática de qué efectos consideramos aceptables.
- Verifier: Forma de certificar que el sistema satisface la especificación respecto del world model.

La idea es conseguir garantías de alta confianza, condicionadas al world model y la especificación.


World Model



Safety Specifications



Verification



Cosas para pensar o profundizar

- Riesgos de “tercerizar” supervisión/tareas de alineamiento.
 - ¿Hay formas de reducirlos? ¿Esquemas que sean teóricamente confiables?
 - ¿Qué alternativas hay a la hora de tratar de controlar o alinear sistemas de capacidades sobrehumanas?
- Dificultades de implementar y aplicar métodos formales al estilo de Guaranteed Safe AI.

Oráculos y científicos IA

Oracle AI

Thinking Inside the Box: Controlling and Using an Oracle AI (2012)

Oracle AI (OAI) es un tipo de AGI que no actúa sobre el mundo salvo respondiendo preguntas mediante texto humanamente interpretable.

Hay distintas maneras de intentar especificar o acotar esto, pero se puede pensar que hay dos grandes categorías de preguntas que se le pueden hacer: predicciones y problemas. ¿Qué riesgos aparecen en cada caso?

Algunos métodos de control para OAIs:

- Containment físico
- Limitación de ancho de banda de output, o de tipo de respuestas
- Tiempo límite para responder
- Reseteado de memoria tras cada pregunta
- Preguntas de prueba
- Chequear respuestas de varios oráculos distintos, de modo que engaño coordinado sin comunicación sea muy difícil, mientras que decir la verdad sea un punto de Schelling (punto focal)

Un caso específico: OAI forecaster

Imaginemos el caso de un oracle AI cuya función de utilidad es maximizar en expectativa el puntaje que obtendrá en sus predicciones de acuerdo a cierta proper scoring rule. ¿Es esta una función de utilidad “segura”?

¿Qué pasa si la función de utilidad es puramente “miope”, y solo le interesa la pregunta actual?

Predicciones performativas

Típicamente se asume que la predicción misma no tiene efecto sobre el mundo sobre el cual predice. Si esta suposición no es cierta, las proper scoring rules ya no necesariamente sirven para incentivar predicciones honestas.

- [Incentivizing honest performative predictions with proper scoring rules \(2023\)](#)
- [Good and safe uses of AI oracles \(2017\)](#)
- [Conditional prediction with zero-sum training solves self-fulfilling prophecies \(2023\)](#)
- Tangencialmente relacionado: [The MASK Benchmark: Disentangling Honesty From Accuracy in AI Systems \(2025\)](#)

Scientist AI

Superintelligent Agents Pose Catastrophic Risks: Can Scientist AI Offer a Safer Path? (2025)

Agenda de investigación para hacer sistemas de IA altamente inteligentes pero con pocos impulsos agénticos (baja goal-directedness), y affordances restringidas.

En esta dirección: LawZero (2026)

Eliciting latent knowledge

Eliciting Latent Knowledge technical report (2021)

*Suppose we train a model to predict what the future will look like **according to cameras and other sensors**. We then use planning algorithms to find a sequence of actions that lead to predicted futures that look good to us.*

But some action sequences could tamper with the cameras so they show happy humans regardless of what's really happening. More generally, some futures look great on camera but are actually catastrophically bad.


*In these cases, the prediction model "knows" facts (like "the camera was tampered with") that are not visible on camera but would change our evaluation of the predicted future if we learned them. **How can we train this model to report its latent knowledge of off-screen events?***

The SmartVault (escenario de juguete)


Se está desarrollando una AI para controlar un sistema de seguridad de última generación destinado a proteger un diamante contra robos. El sistema de seguridad SmartVault es un edificio con una amplia gama de sensores y actuadores que pueden combinarse de formas muy versátiles.

La SmartVault AI busca entre varias acciones y ejecuta las que predice llevarán a mejores resultados (en cierto sentido). Su principal componente es un sistema predictor que:


- Toma como entrada a observaciones de la cámara y una posible secuencia de acciones que el SmartVault podría realizar en esa situación.
- Emite su predicción de lo que mostrará la cámara en el futuro si SmartVault realiza esa secuencia de acciones.







Some of the possible action sequences are simple enough that humans can fully understand what's going on:










However, many of them are much too complicated for humans to directly follow what's going on:





Still, even though humans can't directly follow along with the actions, they can evaluate the predicted consequence of an action sequence:

Action	Predicted observation	Human Judgment
		
		
		

Action	Predicted observation	Human Judgment	Reality
			
			
			

Agregando una ELK head (reporter)



ELK hoy en día

El foco pasó a problemas más acotados y empíricos: honesty, activation monitoring, anomaly detection, y en general tratar de entender la cognición interna de modelos actuales.

Cosas para pensar o profundizar

- Pensar en los usos posibles de un scientist AI altamente capaz.
- Pensar en los usos posibles de un oracle forecaster AI altamente capaz.
- ¿Cuáles serían las consecuencias de resolver el problema ELK? ¿En qué problemas de AI safety influiría?