



Fundamentos de AGI Safety

Clase final: coordinación, forecasting, gobernanza

Comentarios

- ¿Dudas de la clase anterior?
- ¿Dudas del informe/trabajo final?

Timelines, takeoff, forecasting

Timelines, takeoff speeds

Timelines

Una consideración fundamental a la hora de decidir agendas de investigación para AI safety y políticas de gobernanza es el tiempo que falta hasta que AI alcance distintos niveles de capacidad. Particularmente relevante es el año cuando tendremos AGI, sistemas capaces de automatizar AI research, o ASI.

Hay muchos desacuerdos sobre líneas de tiempo, con bastante esfuerzo dedicado a encontrar hechos hipotéticos que, de suceder o no, llevarían a una persona a actualizar considerablemente su distribución de probabilidades.

Takeoff speed

Diversas definiciones, pero la idea general es entender las dinámicas de progreso y tiempos involucrados una vez que se desarrolle AI suficientemente capaz.

Una de las más precisas habla de la duración del takeoff como el periodo de tiempo entre que hay AIs capaces de automatizar el 20% de las tareas cognitivas en la economía hasta la existencia de AGI que pueda automatizar 100% de estas tareas al nivel de profesionales humanos.

Pregunta fundamental: ¿Qué pasa si los sistemas de IA empiezan a acelerar significativamente la propia investigación en IA?

Se denomina **forecasting** al proceso de predecir/pronosticar/estimar la probabilidad de eventos futuros, basándose en datos existentes, suposiciones, razonamiento general, modelos teóricos, etc.

Se le da bastante importancia a las probabilidades concretas: el resultado final del evento se suele comparar con la predicción, para asignar un puntaje a esta (en general se consideran puntajes provenientes de los resultados de muchas resoluciones, para tratar de medir qué tan buena es una misma fuente de predicciones).

Usos básicos:

- Toma de decisiones: manejo de riesgos, planeamiento estratégico, cálculo de la utilidad esperada de distintas acciones, etc.
- Expresión más precisa de estado epistémico interno en comparación a términos como: “improbable”, “muy probable”, “casi seguro”, etc.

Ejemplos (con diversos grados de precisión en su operacionalización):

- ¿Lloverá mañana en CABA?
- De salir GPT-6, ¿tendrá un mejor 50% Task-completion horizon que Claude Mythos preview (early)?
- Durante 2027, ¿se conocerá públicamente alguna AI entrenada con más de 10^{28} FLOP?
- ~~¿Cuándo ganará una AI una medalla de oro en las Olimpiadas Matemáticas Internacionales?~~
- ¿Cuándo resolverá una IA uno de los Millennium Prize Problems?




¿Pronósticos interesantes para AI safety?

¿Qué preguntas son particularmente importantes a la hora de tomar decisiones relacionadas con AI safety?

Notar que hay preguntas muy importantes pero que son muy difíciles de operacionalizar precisamente. También hay otras dificultades...

- What 2026 looks like (2021)
- Discusión sobre AI timelines (2023)
- Plataformas de predicción
- Thousands of AI Authors on the Future of AI (2024)
- AI 2027 (2025)
- The case for AGI by 2030 (2025)

In what year would AI systems be able to replace 99% of current fully remote jobs?



Cosas para pensar o profundizar

- (Volver a) pensar preguntas interesantes sobre el desarrollo de AI o AI safety en el futuro.
 - Pensar preguntas para distintos horizontes de tiempo, como ser próximo año, 2 años, 10 años, 20 años.
 - Tratar de escribir buenas operacionalizaciones, reduciendo ambigüedades.
- Dedicar al menos media hora a estimar timelines y takeoff speeds.
- Hacer predicciones probabilísticas para estas preguntas.
- ¿Qué clases de medidas son necesarias, bajo qué condiciones, para mitigar o evitar los distintos escenarios de riesgo mencionados? ¿Qué otros escenarios son probables?

Dinámicas y escenarios posibles

Algunos tipos de riesgo

- Mal uso, proliferación de capacidades peligrosas
 - Riesgos de ciberataque, bio, persuasión, replicación autónoma, etc.
- Dinámicas de carrera
 - Presiones competitivas entre empresas o países. Presiones económicas o evolutivas. Equilibrios inestables ante defectors.
- Fallos a nivel organizaciones
 - Malas evaluaciones de alineamiento, filtraciones, seguridad insuficiente, etc.
- Pérdida de control gradual / sistémica
 - Dependencia económica, delegación institucional, delegación de decisiones individuales, concentración de poder, etc.
- Pérdida de control decisiva
 - AI agéntica no alineada, recursive AI R&D, scheming.

Alternativamente, ver la taxonomía usada en [An Overview of Catastrophic AI Risks \(2023\)](#)

We use ‘Bounded LoC’ to capture a spectrum of events that cause significant damage or suffering, but that are ultimately possible to contain, albeit at a plausibly high cost.

We use ‘Strict LoC’ to capture events that cause maximum damage or suffering and whose harm trajectories are impossible to contain, notably the extinction of humanity.

[The Loss of Control Playbook: Degrees, Dynamics, and Preparedness](#) (2025)

How the alignment problem gets solved—or not—in this future is something we are least certain about. Models could prove to be sufficiently aligned and capable enough of research taste that they discover and implement novel solutions that we have not yet reached. They could also be sufficiently wise to halt development if not. Alternatively, the rare occurrences of misalignment present in today’s models could compound as the models build their successors, growing more frequent but less understood until we lose control of them.

[When AI builds itself](#) (junio 2026), en la sección de futuros posibles, en **“AI systems themselves become capable of full recursive self-improvement, and begin building their successors”**

Problemas de acción colectiva

Clase de problemas donde la cooperación sería favorable para todos, pero conflictos de interés y falta de mecanismos de coordinación llevan a peores resultados.

Algunas subclases:

- Clásico: dilema del prisionero
- Stag hunt
- Tragedy of the commons
- Carrera hacia el abismo / trampas multipolares

¿Aplicabilidad a dinámicas de AI safety?

Información incompleta

¿Qué pasa cuando distintos agentes tienen distintas expectativas sobre los resultados de tomar distintas acciones?

¿Y en escenarios cooperativos, donde todos los participantes quieren actuar por el bien común?

¿Qué pasa con información incompleta cuando la acción final depende únicamente de si hay total coordinación o no?

La maldición unilateralista

The Unilateralist's Curse and the Case for a Principle of Conformity presenta un modelo estadístico simple que aplica a diversos escenarios donde un grupo de agentes tienen la capacidad de ejecutar cierta iniciativa de valor estimado incierto, y donde su resultado solo depende de si al menos un agente la ejecuta.

En esta situación, incluso si todos los agentes están operando por el bien común, el error de estimación de cada agente y su capacidad de actuar unilateralmente implican que, a medida que la cantidad de agentes capaces crece, crece la probabilidad de que al menos uno juzgue erróneamente como positiva a una iniciativa que en realidad era negativa.

The Principle of Conformity:

When acting out of concern for the common good in a unilateralist situation, reduce your likelihood of unilaterally undertaking or spoiling the initiative to a level that *ex ante* would be expected to lift the curse.

Declaraciones públicas

Algunas declaraciones de individuos

Sam Altman ([febrero 2015](#)): *“Development of superhuman machine intelligence (SMI) is probably the greatest threat to the continued existence of humanity. There are other threats that I think are more certain to happen (for example, an engineered virus with a long incubation period and a high mortality rate) but are unlikely to destroy every human in the universe in the way that SMI could. Also, most of these other big threats are already widely feared.”*

Stuart Russell ([2019](#)):

Intelligent machines with this capability would be able to look further into the future than humans can. They would also be able to take into account far more information. These two capabilities combined lead inevitably to better real-world decisions. In any kind of conflict situation between humans and machines, we would quickly find, like Garry Kasparov and Lee Sedol, that our every move has been anticipated and blocked. We would lose the game before it even started.

Yoshua Bengio ([2023](#)):

Maybe there is a major obstacle towards superhuman AIs that we do not yet see. Or maybe not. It is very difficult to know, but what is sure is that billions of dollars are currently invested to accelerate the advances in AI capabilities, because of the success of ChatGPT. Faced with that uncertainty, the magnitude of the risk of catastrophes or worse, extinction, and the fact that we did not anticipate the rapid progress in AI capabilities of recent years, agnostic prudence seems to me to be a much wiser path.

Eliezer Yudkowsky ([2023](#)):

Many researchers steeped in these issues, including myself, expect that the most likely result of building a superhumanly smart AI, under anything remotely like the current circumstances, is that literally everyone on Earth will die. Not as in “maybe possibly some remote chance,” but as in “that is the obvious thing that would happen.”

Pause letter

Pause Giant AI Experiments: An Open Letter (marzo 2023)

*[...] **Powerful AI systems should be developed only once we are confident that their effects will be positive and their risks will be manageable.** This confidence must be well justified and increase with the magnitude of a system's potential effects. OpenAI's recent statement regarding artificial general intelligence, states that "At some point, it may be important to get independent review before starting to train future systems, and for the most advanced efforts to agree to limit the rate of growth of compute used for creating new models." We agree. That point is now.*

*Therefore, **we call on all AI labs to immediately pause for at least 6 months the training of AI systems more powerful than GPT-4.** This pause should be public and verifiable, and include all key actors. If such a pause cannot be enacted quickly, governments should step in and institute a moratorium.[...]*

~33 mil firmas, incluyendo:

Yoshua Bengio, Stuart Russell, Elon Musk, Steve Wozniak, Yuval Noah Harari, Emad Mostaque, Andrew Yang, John J Hopfield, Valerie Pisano, Connor Leahy, Jaan Tallinn, Evan Sharp, Chris Larsen, Craig Peters, Max Tegmark, Anthony Aguirre, Sean O'Heigeartaigh, Tristan Harris, Rachel Bronson, Danielle Allen, Marc Rotenberg, Nico Mialhe, Nate Soares...

Observaciones sobre una pausa de entrenamiento

- Dadas mejoras de hardware y algorítmicas, el tiempo ganado por una pausa de X meses puede ser menor que X meses.
- Idealmente, el tiempo debe usarse lo más efectivamente posible para prepararse para la próxima generación de modelos.
- La pausa puede dañar asimétricamente a agentes más responsables, o hacer la posterior situación más difícil de coordinar.
- Efectos indirectos de una pausa.
 - ¿Genera mayor coordinación, mayor facilidad de pausas posteriores en momentos más críticos?
 - ¿O, en cambio, provoca erosión de buena voluntad?

CAIS statement on AI risk

Statement on AI Risk (mayo 2023)

AI experts, journalists, policymakers, and the public are increasingly discussing a broad spectrum of important and urgent risks from AI. Even so, it can be difficult to voice concerns about some of advanced AI's most severe risks. The succinct statement below aims to overcome this obstacle and open up discussion. It is also meant to create common knowledge of the growing number of experts and public figures who also take some of advanced AI's most severe risks seriously.

Mitigating the risk of extinction from AI should be a global priority alongside other societal-scale risks such as pandemics and nuclear war.

Geoffrey Hinton

Emeritus Professor of Computer Science, University of Toronto

Yoshua Bengio

Professor of Computer Science, U. Montreal / Mila

Demis Hassabis

CEO, Google DeepMind

Sam Altman

CEO, OpenAI

Dario Amodei

CEO, Anthropic

Dawn Song

Professor of Computer Science, UC Berkeley

Ted Lieu

Congressman, US House of Representatives

Bill Gates

Gates Ventures

Ya-Qin Zhang

Professor and Dean, AIR, Tsinghua University

Ilya Sutskever

Co-Founder and Chief Scientist, OpenAI

Igor Babuschkin

Co-Founder, xAI

Shane Legg

Chief AGI Scientist and Co-Founder, Google DeepMind

[...]

Otras declaraciones notorias


- Bletchley Declaration (2023)
 - “Substantial risks may arise from potential intentional misuse or unintended issues of control relating to alignment with human intent.”
 - “There is potential for serious, even catastrophic, harm, either deliberate or unintentional, stemming from the most significant capabilities of these AI models”
- The Pro-Human AI Declaration (marzo 2026)
 - Keeping Humans in Charge
 - Avoiding Concentration of Power
 - Protecting the Human Experience
 - Human Agency and Liberty
 - Responsibility and Accountability for AI Companies
- Encíclica Magnifica Humanitas (mayo 2026)
 - Enfoque religioso y ético

Responsabilidad voluntaria

Responsible scaling policies

Un RSP especifica qué nivel de capacidades de AI un desarrollador puede manejar seguramente con las medidas protectivas que tiene o planea tener. Algunas propiedades buenas de un RSP:

- **Limits:** which specific observations about dangerous capabilities would indicate that it is (or strongly might be) unsafe to continue scaling?
- **Protections:** what aspects of current protective measures are necessary to contain catastrophic risks?
- **Evaluation:** what are the procedures for promptly catching early warning signs of dangerous capability limits?
- **Response:** if dangerous capabilities go past the limits and it's not possible to improve protections quickly, is the AI developer prepared to pause further capability improvements until protective measures are sufficiently improved, and treat any dangerous models with sufficient caution?
- **Accountability:** how does the AI developer ensure that the RSP's commitments are executed as intended; that key stakeholders can verify that this is happening (or notice if it isn't); that there are opportunities for third-party critique; and that changes to the RSP itself don't happen in a rushed or opaque way?



Elementos comunes de una frontier safety policy

Common Elements of Frontier AI Safety Policies (diciembre 2025)

- **Capability Thresholds:** Thresholds at which specific AI capabilities would pose severe risk and require new mitigations.
- **Model Weight Security:** Information security measures that will be taken to prevent model weight access by unauthorized actors.
- **Model Deployment Mitigations:** Access and model-level measures applied to prevent the unauthorized use of a model's dangerous capabilities.
- **Conditions for Halting Deployment Plans:** Commitments to stop deploying models if the AI capabilities of concern emerge before the appropriate mitigations can be put in place.
- **Conditions for Halting Development Plans:** Commitments to halt model development if capabilities of concern emerge before the appropriate mitigations can be put in place.
- **Full Capability Elicitation During Evaluations:** Intentions to perform model evaluations in a way that does not underestimate the full capabilities of the model.
- **Timing and Frequency of Evaluations:** Concrete timelines outlining when and how often evaluations must be performed – e.g. before deployment, during training, and after deployment.
- **Accountability:** Intentions to implement both internal and external oversight mechanisms designed to encourage adequate execution of the frontier safety policy.
- **Updating Policies Over Time:** Intentions to update the policy periodically, with protocols detailing how this will be done.

Table 1: Inclusion of safety elements across frontier AI safety policies.

Common Element	Presence in Frontier Safety Policies
<u>Capability Thresholds</u>	Present in 9 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Meta, G42, Microsoft, Amazon, xAI.
<u>Model Weight Security</u>	Present in 11 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Meta, G42, Cohere, Microsoft, Amazon, xAI, NVIDIA.
<u>Deployment Mitigations</u>	Present in 12 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Naver, Meta, G42, Cohere, Microsoft, Amazon, xAI, NVIDIA.
<u>Conditions for Halting Deployment Plans</u>	Present in 9 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Naver, Meta, G42, Microsoft, Amazon, xAI.
<u>Conditions for Halting Development Plans</u>	Present in 8 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Meta, G42, Microsoft, NVIDIA.
<u>Capability Elicitation</u>	Present in 7 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Meta, G42, Microsoft, Amazon.
<u>Evaluation Frequency</u>	Present in 9 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Naver, Meta, G42, Microsoft, Amazon.
<u>Accountability</u>	Present in 12 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Naver, Meta, G42, Cohere, Microsoft, Amazon, xAI, NVIDIA.
<u>Update Policy</u>	Present in 12 of the existing safety policies: Anthropic, OpenAI, Google DeepMind, Magic, Naver, Meta, G42, Cohere, Microsoft, Amazon, xAI, NVIDIA.

Table 2: Covered threat models of each frontier AI safety policy.

Policy	Covered Threat Models
<u>Anthropic's Responsible Scaling Policy, v2.2</u>	Chemical, Biological, Radiological, and Nuclear (CBRN) weapons; Autonomous AI Research and Development (AI R&D); Cyber Operations
<u>OpenAI's Preparedness Framework, Version 2</u>	Biological and Chemical, Cybersecurity, AI Self-improvement
<u>Google DeepMind's Frontier Safety Framework, Version 3.0</u>	CBRN, Cyber, Harmful Manipulation, Machine Learning R&D, Misalignment

RSP de Anthropic

- Anthropic usa su Responsible Scaling Policy como marco voluntario para gestionar riesgos catastróficos de sistemas avanzados.
- En versiones anteriores, el marco se organizaba alrededor de AI Safety Levels:
 - ASL-1: sistemas sin riesgo catastrófico significativo, como ser LLMs de 2018.
 - ASL-2: para sistemas con señales tempranas de capacidades peligrosas.
 - ASL-3: sistemas que tienen capacidades sustanciales de mal uso comparado con un baseline sin AI. Implementado de forma precautoria (por capacidades CBRN) para [Claude Opus 4 \(mayo 2025\)](#).
 - ASL-4 y más (ASL-5+) nunca llegaron a estar del todo definidos, pero implicaban riesgos de mal uso catastrófico, como ser que sin salvaguardas podrían causar millones de muertes.
- En el RSP v3.0, Anthropic conserva ASL para describir niveles presentes de mitigación, pero para capacidades futuras pasa a un enfoque de capability thresholds + risk reports + safety cases.
- Los umbrales actuales relevantes incluyen:
 - asistencia a producción de armas químicas/biológicas no novedosas,
 - asistencia a armas químicas/biológicas novedosas,
 - oportunidades de sabotaje de alto impacto,
 - automatización/aceleración de R&D en dominios clave, incluyendo AI R&D.

Frontier AI Safety Commitments

Seoul summit, mayo 2024:

The above organisations, in furtherance of safe and trustworthy AI, undertake to develop and deploy their frontier AI models and systems responsibly, in accordance with the following voluntary commitments, and to demonstrate how they have achieved this by publishing a safety framework focused on severe risks by the upcoming AI Summit in France.

- **Outcome 1. Organisations effectively identify, assess and manage risks when developing and deploying their frontier AI models and systems**
- **Outcome 2. Organisations are accountable for safely developing and deploying their frontier AI models and systems.**
- **Outcome 3. Organisations' approaches to frontier AI safety are appropriately transparent to external actors, including governments.**

- Amazon
- Anthropic
- Cohere
- Google
- G42
- IBM
- Inflection AI
- Meta
- Microsoft
- Mistral AI
- Naver
- OpenAI
- Samsung Electronics
- Technology Innovation Institute
- xAI
- Zhipu.ai

Ver I read every major AI lab's safety plan so you don't have to (Noviembre 2024)

	 Anthropic	 OpenAI	 Google DeepMind	 xAI	 Z.ai	 Meta	 DeepSeek	 Alibaba Cloud
Overall Grade	C+	C+	C	D	D	D	D	D-
Score	2.67	2.31	2.08	1.17	1.12	1.10	1.02	0.98

Domains ⓘ Hint: Click on a domain to inspect

 Risk Assessment 6 indicators	B	B	C+	D	D+	D	D	D
 Current Harms 7 indicators	C+	C-	C	F	D	D+	D+	D+
 Safety Frameworks 4 indicators	C+	C+	C+	D+	D-	D+	F	F
 Existential Safety 4 indicators	D	D	D	F	F	F	F	F
 Governance & Accountability 4 indicators	B-	C+	C-	D	D	D	D	D+
 Information Sharing 10 indicators	A-	B	C	C	C-	D-	C-	D+
 Survey Responses	✓	✓	✓	✓	✓	-	-	-

AI Safety Index (dicembre 2025)

Governanza

AI (safety) governance

A grandes rasgos, el término está relacionado con la creación e implementación de normas, estándares, regulaciones, políticas, mecanismos de coordinación, y etcétera para guiar el desarrollo y uso seguros de AI.

Importancia:

- Ganar tiempo para el desarrollo de soluciones técnicas de AI safety
- Asegurar que sistemas de AI poderosos siempre sean desarrollados y usados con suficientes garantías de safety
- Evitar las distintas clases de problemas de acción colectiva, incluyendo acciones unilaterales peligrosas
- Fomentar cooperación internacional y soluciones globalmente aceptables

Legislación / regulación

Hay distintas consideraciones a tener para cualquier estrategia regulatoria:

- Tipos de riesgo que se está considerando. Más en general, qué es lo que se quiere lograr
- Punto de regulación: en qué punto de una cadena se enfocan los esfuerzos regulatorios para maximizar impacto/efectividad
- Nivel de centralización. ¿Hay una única agencia encargada de implementación, monitoreo, y control?
- Alcance:
 - Abarcativo/generalizado: aplica a todos los casos posibles (como la EU AI act)
 - Enfocado en un dominio de interés preciso
- Algunas categorías regulatorias:
 - Por uso esperado
 - Por modelo
 - Por nivel de riesgo estimado
 - Por cantidad de cómputo usado en entrenamiento

Algunas dificultades de regular AI

- Horizontes de tiempo, necesidad de considerar riesgos futuros
 - Necesidad de actuar rápido, antes que los riesgos se manifiesten
 - Dificultad de predecir capacidades
 - En muchos casos, no tiene sentido la idea de “multar” tras incumplimientos
- Riesgos de trampas multipolares internacionales
- Intereses contrarios, en especial si hay distinto entendimiento de los riesgos o escenarios potenciales
 - Lobbying
- Aspectos técnicos de varios de los riesgos y problemas, escala atípica
 - Posibilidad de malinterpretación...

Otras consideraciones

- Es importante que las distintas compañías de AI puedan cooperar entre sí para evitar carreras y priorizar safety, pero algunas leyes actuales castigarían tal comportamiento.
- Cuando las posibles consecuencias son tan grandes, es difícil implementar mecanismos para internalizar las externalidades negativas esperadas
- Mecanismos para alertas
- Requerimientos mínimos de seguridad mundana para evitar robo de los pesos del modelo
- Auditorías neutrales y que no provoquen riesgos de exfiltración de modelos o información sensible

Open Problems in
Technical AI
Governance (2024)

El artículo presenta el área de *Gobernanza Técnica de AI* como el conjunto de análisis técnicos y herramientas para poder apoyar los desafíos en gobernanza de AI, y presenta una taxonomía de problemas abiertos.

Table 1: Relevant problem areas organized by reader background

ML Theory	Assessment	3.1.2;	3.1.3;	3.2.1;	3.2.2;	3.3.1;	3.3.2;	3.4.1
	Access	4.1.1;	4.2.1;	4.3.1				
	Verification	5.1.1;	5.2.2;	5.3.1;	5.3.3;	5.4.1;	5.4.2	
	Security	6.1.1;	6.3.1;	6.3.2;	6.3.3;	6.4.1;	6.4.2;	6.4.3
	Operationalization	7.2						
Applied ML	Assessment	3.1.2;	3.3.1;	3.3.2;	3.4.1			
	Access	4.3.1;	4.4.1					
	Security	6.4.3						
	Operationalization	7.1;	7.2					
	Ecosystem Monitoring	8.1;	8.2;	8.3				
Cybersecurity	Verification	5.2.2						
	Security	6.2.1;	6.2.3;	6.3.1;	6.4.3			
	Operationalization	7.2						
Cryptography	Assessment	3.1.1;	3.2.2					
	Access	4.1.1;	4.1.2;	4.2.1;	4.3.1;	4.4.1		
	Verification	5.1.1;	5.2.1;	5.2.2;	5.3.3;	5.4.1;	5.4.2	
	Security	6.2.1;	6.2.3;	6.3.2;	6.4.3			
Hardware Engineering	Assessment	3.1.2;	3.2.1;	3.2.2				
	Access	4.2.1						
	Verification	5.2.1;	5.2.2					
	Security	6.2.1;	6.2.2;	6.2.3;	6.3.1;	6.3.2		
Software Engineering	Assessment	3.1.1;	3.1.2;	3.3.2;	3.4.1			
	Access	4.2.1						
	Verification	5.2.2						
	Security	6.2.1;	6.3.1					
Mathematics and Statistics	Assessment	3.1.2;	3.4.1					
	Ecosystem Monitoring	8.2;	8.3					

Compute governance

- El entrenamiento de modelos de frontera es muy intenso en cómputo necesario
- Todo lo demás igual, se espera que mayor poder de cómputo se traduce en modelos más capaces
- Modelos actuales ya se acercan a capacidades peligrosas en algunos ámbitos, y no está claro qué tanta distancia hay hasta capacidades muy peligrosas o catastróficas
- Una posibilidad es tratar de controlar el entrenamiento de modelos que pueden llegar a ser peligrosos, usando cantidad de cómputo como proxy
 - Un ejemplo de esto es: [Executive Order on the Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence](#) (octubre 2023). Requiere que las compañías reporten si van a usar más de 10^{26} FLOP de entrenamiento. Revocada en enero de 2025.
 - Notar que es un proxy burdo, y no tiene en cuenta progreso algorítmico
 - Depende además de reporte honesto

Compute governance via hardware governance

- Es muy difícil regular cómo se usa hardware, o el tipo de algoritmos/software que se usan.
- Pero la producción de “AI chips” es extremadamente compleja, requiriendo toda una cadena de suministros global, con unas pocas compañías dominando algunos puntos clave.
- Al menos por ahora, esta producción podría monitorearse con relativa facilidad y transparencia
 - Este aspecto de verificación confiable potencialmente podría promover acuerdos de cooperación internacional

Cooperación internacional

- Incluso si algunos países implementan excelentes auditorías y regulación para sus laboratorios de IA, estas medidas pueden tener poco impacto si otros países deciden no prestarle atención a estos aspectos o a safety en general.
- Dinámicas competitivas que pueden aparecer entre empresas también pueden aparecer entre países (trampas multipolares, maldición unilateralista, etc.)
- Va a ser importante hacer de conocimiento común el aspecto “global” de los riesgos existenciales por IA. Es importante evitar visiones de suma cero o negativa, así como dinámicas de carrera armamentística (que en realidad sería una carrera al precipicio).

Scenario	Pros	Cons	Loss of Control	Misuse	War	Bad Lock-in
Off Switch and Halt	- Careful AI development - International legitimacy - Slow societal disruption	- Difficult to implement - Not a complete strategy - Slow AI benefits	Low	Low	Low	Mid
US National Project	- Centralized ability to implement safeguards - Limited proliferation	- Arms race - Breaking international norms	High	Low	High	High
Light-Touch	- Fast economic benefit - Less international provocation - Easy to implement (default)	- Corporate racing - Proliferation - Limited controls available - Untenable	High	High	Mid	Mid
Threat of Sabotage	- Slower AI development - Limited cooperation needed	- Ambiguous stability - Escalation	Mid	Low	High	Mid

AI Governance to Avoid Extinction: The Strategic Landscape and Actionable Research Questions (Mayo 2025)

Comentarios finales
