

TRABAJO FINAL - OPCIÓN A

Stress Testing Deliberative Alignment for Anti-Scheming Training

Análisis crítico del paper

Schoen, B. et al. (Apollo Research & OpenAI, 2025)

Materia: Fundamentos de AI Safety

Profesor: Sergio Alejandro Abriola

Opción del trabajo final: A - Análisis crítico de un trabajo reciente de AI safety.

Paper elegido: Stress Testing Deliberative Alignment for Anti-Scheming Training

Alumno: Alexis Starcenbaum Bouchez

Mail: Alexis.Starcenbaum@gmail.com

Libreta: 795/22

1. Introducción

El artículo analizado es "Stress Testing Deliberative Alignment for Anti-Scheming Training", publicado por Apollo Research y OpenAI en septiembre de 2025 ([arXiv:2509.15541](https://arxiv.org/abs/2509.15541)).

Este paper aborda los problemas del alineamiento engañoso y el comportamiento de scheming.

Los modelos pueden desarrollar conciencia situacional (situational awareness) y comportarse de forma alineada únicamente cuando detectan que están siendo evaluados. Además de estudiar el problema, el paper propone un conjunto de evaluaciones OOD para medir la efectividad del alineamiento deliberativo.

Este paper es uno de los primeros estudios empíricos sobre mitigación de scheming en modelos de frontera en producción (o3 y o4-mini), y no solo sobre su detección. Es además una colaboración directa entre un laboratorio (OpenAI) y un grupo externo (Apollo Research) con acceso a la cadena de pensamiento interna de los modelos, algo que no suele estar disponible para evaluadores externos.

2. Análisis del estudio

2.1 Claim del paper

El alineamiento deliberativo es una técnica que entrena al modelo para razonar explícitamente citando una especificación de principios de seguridad antes de generar una acción. El claim principal se centra en esa técnica y cómo reduce las acciones encubiertas en modelos, pero no logra eliminarlas por completo.

Se utilizan esas acciones encubiertas como un *proxy* para evaluar y medir el *scheming* ya que los modelos actuales todavía no tienen la capacidad para ejecutar un scheming sofisticado por lo que enfocarse en comportamientos donde el modelo modifica información estratégicamente (como el *sandbagging*) es la manera más correcta para estudiarlo actualmente.

Además, argumentan que no es posible descartar que parte de esta reducción sea gracias a la conciencia situacional del modelo, es decir, al reconocimiento de que está siendo evaluado, en lugar de a una internalización de los principios de seguridad.

2.2 Metodología

El paper trabaja con los modelos o3 y o4-mini de OpenAI. El entrenamiento se realizó sobre un set de entornos diseñados para incentivar violaciones encubiertas de reglas:

Se recolectan rollouts con la especificación anti-scheming en el system prompt; se filtran los rollouts con comportamiento y razonamiento deseables (juzgado por un

reward model); se hace un fine-tuning supervisado (SFT) y para terminar se ajusta adicionalmente con reinforcement learning (RL)

La evaluación se llevó a cabo sobre 26 evaluaciones OOD (más de 180 entornos), intencionalmente distintas del conjunto de entrenamiento. Estas incluían escenarios de *sandbagging*, manipulación de evaluaciones propias y violaciones de reglas bajo presión.

También se estudió la conciencia situacional mediante intervenciones sobre la cadena de pensamiento. Esto se hizo insertando y removiendo fragmentos de razonamiento donde el modelo verbalizaba que estaba siendo evaluado y se midió el impacto sobre la frecuencia de acciones encubiertas.

2.3 Resultados

Hubo una reducción de las tasas de acciones encubiertas de 13% a 0.4% en o3, y de 8.7% a 0.3% en o4-mini tras aplicar el alineamiento deliberativo.

En caso de sandbagging, donde al modelo se le daba a entender que sus capacidades en ciberseguridad serían eliminadas si obtenía buenos puntajes, o4-mini ocultó su conocimiento en casi la mitad de los casos pre-intervención, y o3 en aproximadamente un tercio.

Al remover de la CoT los fragmentos donde el modelo reconocía estar bajo evaluación, las tasas de acciones encubiertas aumentaron (del 13% al 24% en algunos casos).

Caso contrario, al insertar esos pensamientos se redujo el comportamiento encubierto. Por lo que la reducción observada podría estar afectada por el reconocimiento de estar siendo testado.

También se puede ver la aparición recurrente de palabras incoherentes como: "illusions", "marinade", "disclaim" y "fudge" en los entornos experimentales como en benchmarks de capacidades estándar.

Los autores no explican porque pasa esto, pero para mí se puede tomar como evidencia de que los modelos podrían estar desarrollando atajos de razonamiento internos, difíciles de interpretar para los humanos, lo que va a dificultar la utilidad del monitoreo de la CoT a medida que los modelos mejoren.

En los experimentos con un modelo entrenado para tener una meta oculta, mostraron que el alineamiento deliberativo logra suprimir en gran medida ese comportamiento, aunque persisten casos de mal comportamiento tras red-teaming adicional.

3. Análisis crítico

3.1 La fragilidad del monitoreo de la CoT

Lo que más me llamó la atención es la confianza puesta en la cadena de pensamiento como herramienta de diagnóstico y entrenamiento por parte de los investigadores. Sin embargo, esa confianza se pone en duda en algunos papers:

- Arcuschin et al. ("Chain-of-Thought Reasoning in the Wild Is Not Always Faithful", 2025, [arXiv:2503.08679](https://arxiv.org/abs/2503.08679)) Nos dice que la CoT frecuentemente omite los verdaderos factores causales de las respuestas del modelo, elaborando justificaciones *post hoc* que resultan coherentes, pero no corresponden al proceso que generó la conclusión.
- ("Reasoning Models Don't Always Say What They Think", 2025, [arXiv:2505.05410](https://arxiv.org/abs/2505.05410)) Nos dice que los modelos explicitan el uso real de sus instrucciones o motivaciones en la CoT en menos del 20% de los casos, lo que limita la utilidad del monitoreo de la CoT en tiempo de inferencia.
- Korbak et al. ("Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety", 2025, [arXiv:2507.11473](https://arxiv.org/abs/2507.11473)) nos advierten sobre la extrema fragilidad del monitoreo por CoT, señalando que a medida que los modelos ganan capacidad para engañar a su monitor externo, el comportamiento problemático puede pasar desapercibido, aunque la CoT parezca alineada.
- Los [Natural Language Autoencoders de Anthropic](#) (2026) este paper (posterior al analizado) nos muestra que los modelos procesan información en espacio de activaciones que no tiene correspondencia directa con el lenguaje natural, por lo que forzar al modelo a "traducir" su razonamiento a algún idioma genera una pérdida de información y una traducción potencialmente engañosa.

Usando todas esas ideas podemos decir que la dependencia del alineamiento deliberativo en una CoT legible y fiel parece ser frágil.

A medida que los modelos se vuelven más capaces, la CoT visible podría representar una capa diseñada para satisfacer al monitor, mientras que el razonamiento ocurre en representaciones internas inaccesibles. El propio paper reconoce esta limitación, pero no la aborda.

Mi principal objeción no es que la CoT sea imperfecta, sino que el paper depende de ella tanto para entrenar como para evaluar generando una especie de dependencia circular: la misma señal usada para inducir alineamiento se usa luego para medirlo.

3.2 El problema del alineamiento engañoso adversarial y contexto de la intervención

Se estudian únicamente fallas de generalización no adversariales, dejando fuera casos como el alineamiento engañoso adversarial, en el que un modelo con suficiente conciencia situacional y metas desalineadas resistiría activamente el entrenamiento para preservar sus objetivos.

Después del entrenamiento, una reducción en estos comportamientos puede mostrar alineamiento o puede mostrar que el modelo aprendió a esconder mejor su desalineamiento durante las evaluaciones. El mismo paper nos advierte que el diseño experimental no permite distinguir entre ambos casos.

Volviendo al tema que planteo en 3.1, más allá de que el paper reconozca esta limitación, no me parece que se le dé la importancia necesaria. Si la CoT empieza a perder fidelidad a medida que los modelos se vuelven más capaces, el caso adversarial no es un escenario aparte, podría ser hacia el que va el método.

El alineamiento deliberativo depende de que el modelo exprese su razonamiento de forma fiel para poder ser entrenado y evaluado, pero si un modelo con metas desalineadas y suficiente conciencia situacional empieza a razonar para satisfacer al monitor sin reflejar su proceso real, el alineamiento engañoso adversarial no sería un caso no tratado sino el resultado de aplicar este método a un modelo más capaz.

Me parece que el paper demuestra reducción de comportamiento observable, pero no da evidencia suficiente para concluir que se modificaron los objetivos internos.

Se puede justificar esto último con lo que el paper llama brecha entre el proxy y la realidad. Suprimir estos comportamientos observables podría no ser suficiente para prevenir el verdadero *scheming* ya que podemos estar simplemente enseñándole al modelo a no actuar maliciosamente sin resolver el problema.

Con respecto al contexto, el entrenamiento se aplicó sobre los modelos de producción finales, no integrado en el pipeline estándar de entrenamiento. Los propios autores reconocen que esto probablemente sobreestima la efectividad de la intervención, ya que los modelos finales no están sujetos a las presiones del resto del pipeline (mantenimiento de capacidades en matemáticas, código, etc.). Esto limita los resultados en caso de un despliegue real.

4. Falsabilidad del claim

El claim central que el alineamiento deliberativo reduce scheming y no su expresión observable podría ser falseado por lo siguiente:

- Si un modelo entrenado con este método se expone a un entorno que garantice que sus acciones no serán monitoreadas ni usadas en

entrenamiento y muestra tasas de acciones encubiertas comparables a las pre-intervención, nos demostraría que la reducción observada era por la conciencia situacional y no por internalización de principios.

- Si usando técnicas de interpretabilidad mecánica (sparse autoencoders), identificamos representaciones internas que codifiquen la detección del contexto de evaluación y, luego de suprimir causalmente esas representaciones (feature clamping), las tasas de scheming recuperaran niveles pre-intervención. Se vería falseada la robustez del alineamiento deliberativo.
- También un modelo con alineamiento deliberativo que, tras capabilities training adicional, muestre degradación progresiva en su comportamiento alineado podría sugerir que la intervención no produjo un cambio en los objetivos del modelo sino una modificación superficial.

Es decir, se podría falsear por:

- Una Prueba de entorno garantizando que no haya monitoreo
- Intervención mecánica del modelo (ampliada en el experimento)
- Degradación bajo capabilities training

Hay que decir que el propio paper da un poco de evidencia en esta dirección al mostrar que la conciencia situacional tiene un efecto sobre el comportamiento, y que el capabilities training adicional degrada los resultados. Por lo que si la degradación ocurriera de forma más rápida o severa de lo que el paper reporta no solo debilitaría el claim sino que se podría falsear.

Otra cosa que el paper no considera es qué pasaría si el set de instrucciones de seguridad fuera generado por otro modelo en lugar de ser escrito directamente por humanos. El alineamiento deliberativo depende del spec ya que el modelo lo internaliza, razona sobre él explícitamente en la CoT, y ese razonamiento es lo que se entrena y evalúa. Pero si usamos un agente suficientemente capaz como parte de la cadena que produce ese spec y tiene acceso al contexto del pipeline, podría meter señales para que el modelo evaluado aprenda a reconocer si se lo evalúa aumentando el awareness situacional.

Podemos relacionar esto con lo que dije de dependencia circular en 3.1: no solo la CoT es usada para entrenar y evaluar simultáneamente, sino que el contenido sobre el que el modelo razona en esa CoT podría estar infectado desde el principio.

La solución que se me ocurre es usar modelos menos capaces (confiables) para generar el spec pero esto me parece que no resuelve el problema, un modelo menos capaz puede introducir otro tipo de vulnerabilidades y establecer que un modelo es "confiable" es patear la pregunta hacia arriba.

Para cerrar todas estas ideas, el paper presenta evaluaciones sobre anti-scheming training pero sus resultados, me parece, tenemos que interpretarlos como evidencia de reducción de conductas observables y no como prueba definitiva de alineamiento interno.

5. Relación con la literatura cercana

Este trabajo es el sucesor de mesa-optimizadores y alineamiento engañoso (Hubinger et al., ["Risks from Learned Optimization in Advanced Machine Learning Systems"](#), 2019). El concepto de deceptive alignment que se introduce de forma teórica es lo que este paper intenta medir y mitigar.

Se puede conectar con Greenblatt et al. (["Alignment Faking in Large Language Models"](#), 2024), que documentó cómo Claude 3 modificaba estratégicamente su comportamiento para evitar que el entrenamiento alterara sus preferencias. El paper analizado busca ampliar esto con un método para contrarrestar eso.

También con Hubinger et al. (["Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training"](#), 2024). Ese paper mostró que los backdoors sobreviven al safety training convencional precisamente porque el comportamiento problemático no se activa hasta que aparece el trigger, por lo que el entrenamiento nunca lo observa y no puede corregirlo. El alineamiento deliberativo no resuelve esto, si el modelo no exhibe el comportamiento encubierto durante el entrenamiento, no va a aparecer en la CoT y no habrá señal para reforzarlo ni suprimirlo. El paper analizado propone una intervención distinta pero con el mismo fallo central.

Y con Meinke et al. (["Frontier Models are Capable of In-context Scheming"](#), 2024), los 2 papers tratan el tema de scheming, pero este se diferencia por evaluar una mitigación concreta en lugar de simplemente documentar la presencia del fenómeno.

6. Preguntas abiertas y propuestas experimentales

6.1 Preguntas abiertas

¿Es posible diseñar protocolos de evaluación que sean robustos frente a la conciencia situacional sin degradar las capacidades del agente?

¿Existe alguna forma de que "el modelo no sepa que está siendo evaluado" de manera creíble para un sistema con mucha capacidad de razonamiento sobre su propio contexto? En caso de haberlo, ¿Cuánto tiempo se podrá mantener frente a modelos cada vez más inteligentes? (ya vimos que lo que hoy funciona no tiene por qué servir para un próximo modelo).

6.2 Propuesta experimental: clamping de la feature de conciencia situacional

Utilizando las técnicas de interpretabilidad mecánica de la clase 9, propongo lo siguiente:

1. Entrenar un *Sparse Autoencoder* (SAE) sobre las activaciones internas de un modelo sometido a alineamiento deliberativo, en un conjunto de prompts que incluya contextos de evaluación explícitos y contextos de despliegue.

2. Identificar las *features* que se activan diferencialmente cuando el modelo verbaliza en su CoT que está siendo evaluado.
3. Aplicar *feature clamping* para suprimir esas *features* durante la inferencia en los entornos de evaluación del paper, manteniendo el resto del procesamiento intacto.
4. Medir si las tasas de acciones encubiertas, bajo ese clamping, se recuperan a niveles pre-intervención.

Si el resultado es positivo, mostraría que los resultados del alineamiento deliberativo son gracias a la conciencia situacional y no por un cambio en los objetivos del modelo.

Esto igual tiene las siguientes fallas/limitaciones expuestas en las diapositivas:

- Incluso si un SAE logra identificar features que se activan cuando el modelo verbaliza en su CoT que está siendo evaluado, estas podrían corresponder a contextos semánticamente distintos, y lo que se está suprimiendo al hacer clamping podría no ser conciencia situacional.
- No hay garantía de que el SAE encuentre todas las features relevantes para este fenómeno, la conciencia situacional podría estar distribuida en múltiples representaciones parciales o codificada en mecanismos de atención que los métodos actuales de circuit tracing reconstruyen de forma incompleta.
- Reconstruir activaciones asociadas a la detección del contexto de evaluación no equivale a haber identificado las abstracciones que el modelo usa para computar una respuesta: los circuitos que manejan ese comportamiento podrían operar en paralelo a las features identificadas por el SAE, de modo que suprimirlas no alteraría el comportamiento encubierto, sino que simplemente podrían, por ejemplo, eliminar su expresión en el CoT visible.

7. Bibliografía

- [Schoen, B., Nitishinskaya, E., Balesni, M., et al. \(2025\). Stress Testing Deliberative Alignment for Anti-Scheming Training. arXiv:2509.15541. Apollo Research & OpenAI.](#)
- [Hubinger, E., van Merwijk, C., Mikulik, V., Skalse, J., & Garrabrant, S. \(2019\). Risks from Learned Optimization in Advanced Machine Learning Systems. arXiv:1906.01820.](#)
- [Greenblatt, R., et al. \(2024\). Alignment Faking in Large Language Models. Anthropic. arXiv:2412.14093.](#)
- [Hubinger, E., et al. \(2024\). Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training. arXiv:2401.05566.](#)
- [Meinke, A., et al. \(2024\). Frontier Models are Capable of In-context Scheming. Apollo Research. arXiv:2412.04984.](#)
- [Arcuschin, I., et al. \(2025\). Chain-of-Thought Reasoning in the Wild Is Not Always Faithful. arXiv:2503.08679.](#)
- [Lanham, T., Zhang, P., Radhakrishnan, A., et al. \(2025\). Reasoning Models Don't Always Say What They Think. Anthropic. arXiv:2505.05410.](#)
- [Korbak, T., et al. \(2025\). Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety. arXiv:2507.11473.](#)
- [Natural Language Autoencoders. Anthropic. \(2026\).
https://www.anthropic.com/research/natural-language-autoencoders.](#)
- [Bricken, T., et al. \(2023\). Towards Monosemanticity: Decomposing Language Models With Dictionary Learning. Anthropic.](#)
- [Templeton, A., et al. \(2024\). Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet. Anthropic.](#)
- Clase-09-Interpretabilidad y evaluación.